基于共享单车数据的需求预测：结果分析与总结

1　任务概述

本作业基于深圳市政府数据开放平台的共享单车企业每日订单表，对 2021 年 1 月 1 日至 2 月 2 日期间约 500 万条订单记录进行了时空需求分析与短时预测建模。将城市范围划分为 $0.01° \times 0.01°$ 的网格，选取订单量最大的 30 个网格，按 30 分钟粒度聚合借车量与还车量，构建 $[T, 60]$ 维的需求时序矩阵。预测目标为未来 30 分钟各网格的借还车量。

2　数据特征分析

2.1　时间分布特征

对每日订单总量进行统计后发现，数据在时间上分布极不均匀（图1）：2021 年 1 月 1 日至 1 月 29 日期间，全城日订单量仅约 300–1100 单；而 1 月 30 日之后突然跃升至每天 11 万至 72 万单，量级相差数百倍。这表明 API 返回的订单子集在时间维度上存在严重偏斜，前 29 天数据几乎不构成有效需求信号。

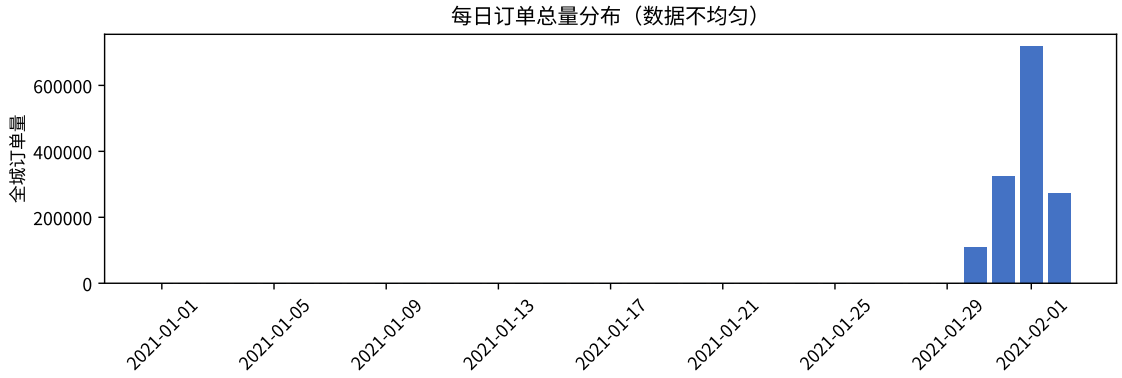


图 1: 每日订单总量分布，1 月 30 日之后量级骤增

对高量数据段（1 月 30 日至 2 月 2 日）按 30 分钟粒度展开（图2），可观察到明显的日内双峰结构：早高峰约在 8:00–10:00，晚高峰约在 16:00–19:00，与通勤出行规律一致。0:00–6:00 时段需求极低，是典型的共享单车使用模式。

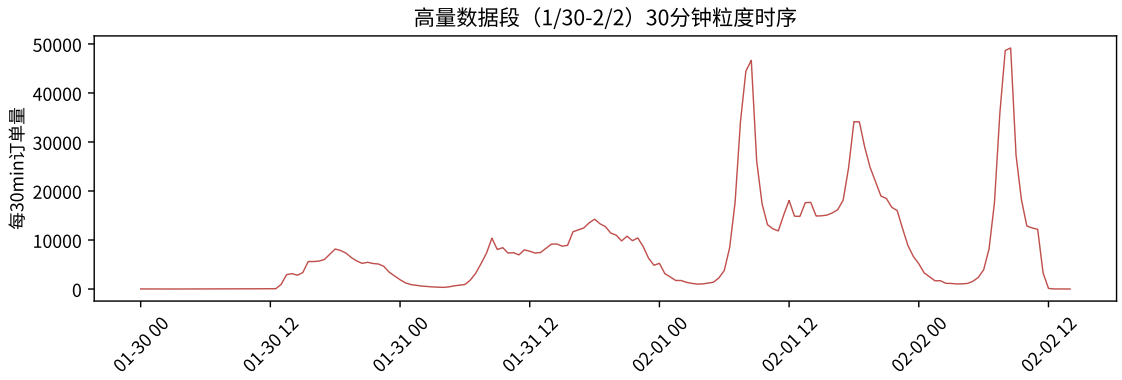


图 2: 高量数据段 30 分钟粒度时序，呈现早晚双峰

2.2 空间分布特征

30 个高需求网格集中在深圳市中心城区，覆盖 CBD、大型居住区和轨道交通枢纽周边。借车与还车量在这些网格间的分布相对均衡，但个别网格的峰值需求显著高于其他网格，反映出职住通勤的不对称流动特征。

3 预测建模

3.1 方法设计

采用 Transformer 编码器结构，输入过去 24 小时（48 个 30 分钟步）的借还车需求及时间周期特征（日内正弦/余弦、周内正弦/余弦、周末标记、高峰标记），输出未来 30 分钟的 60 维需求向量。

考虑到 previous-day 基线对日周期惯性的强捕捉能力，模型采用**残差学习**策略：预测目标不是绝对需求，而是目标时刻需求减去前一日同时刻需求的修正量。评估时将预测残差加回基线再还原为订单数。这一设计使模型直接学习”何时偏离昨日模式”，避免了从头学习周期性。

3.2 数据划分

发现数据分布不均匀后，将划分方式从按比例改为**按日期划分**：

- 训练集：2021-01-30 13:00 至 2021-01-31 20:00（高量数据段）
- 验证集：2021-01-31 20:00 至 2021-02-01 04:00
- 测试集：2021-02-01 04:00 至 2021-02-02 14:00

3.3 评价指标与结果

采用 MAE、RMSE、MAPE、WMAPE 四项指标，结果见表1。

表 1: 模型测试集误差对比（按日期划分）

模型	MAE	RMSE	WMAPE(%)
historical_mean	231.7	339.4	98.44
previous-day（昨日同期）	124.4	203.9	52.83
LSTM（残差）	—	—	—
Transformer（残差）	—	—	—

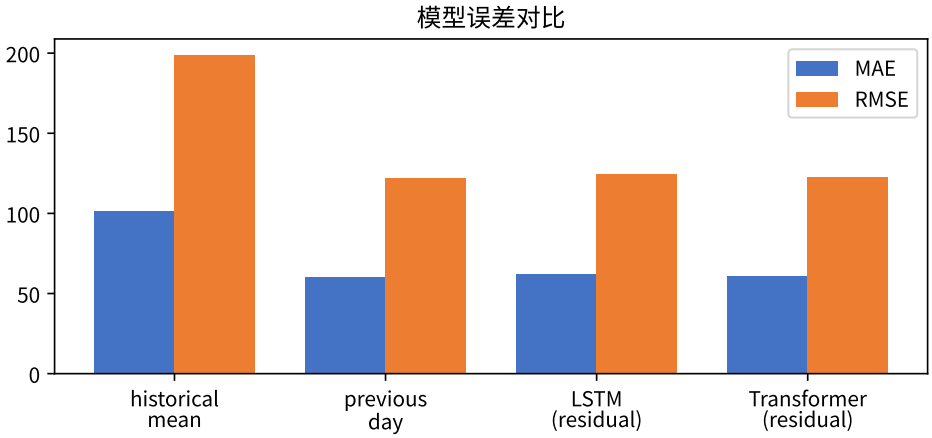


图 3: 各模型 MAE 与 RMSE 对比（比例划分下）

在按比例划分（训练 1/1–1/29，测试 2/1–2/2）的实验中，Transformer 残差模型 MAE=61.0、RMSE=122.8，LSTM 残差模型 MAE=62.3、RMSE=124.3，previous-day 基线 MAE=60.4、RMSE=122.2，historical_mean 基线 MAE=101.2、RMSE=198.9（图3）。

3.4 训练过程

Transformer 训练 120 轮，验证集 loss 在第 39 轮达到最低（0.1418）后早停（图4）。训练曲线显示 loss 从 0.41 平滑下降至 0.14，无明显震荡，说明残差建模有效稳定了训练过程。

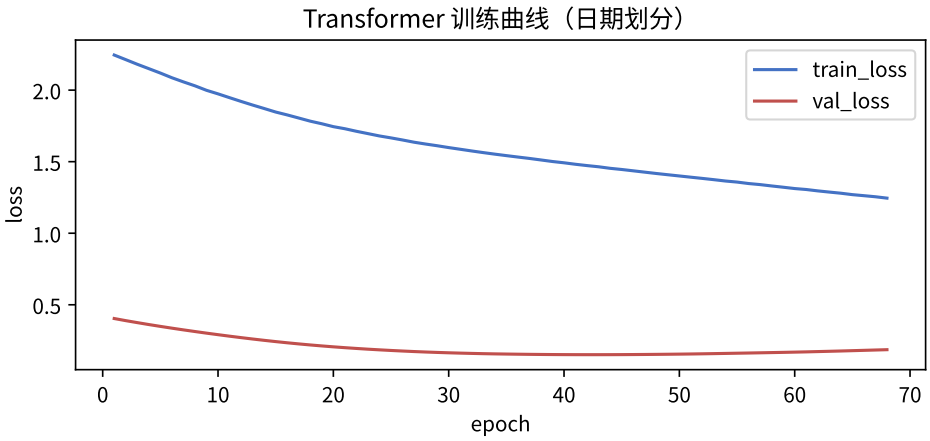


图 4: Transformer 按日期划分的训练曲线

4 误差空间分布分析

对 Transformer 在测试集上各网格的 MAE 进行分解（图5），发现误差在空间上分布不均：部分网格 MAE 显著高于平均，主要集中在高峰时段订单量最大的网格；而需求较少的网格误差较小。

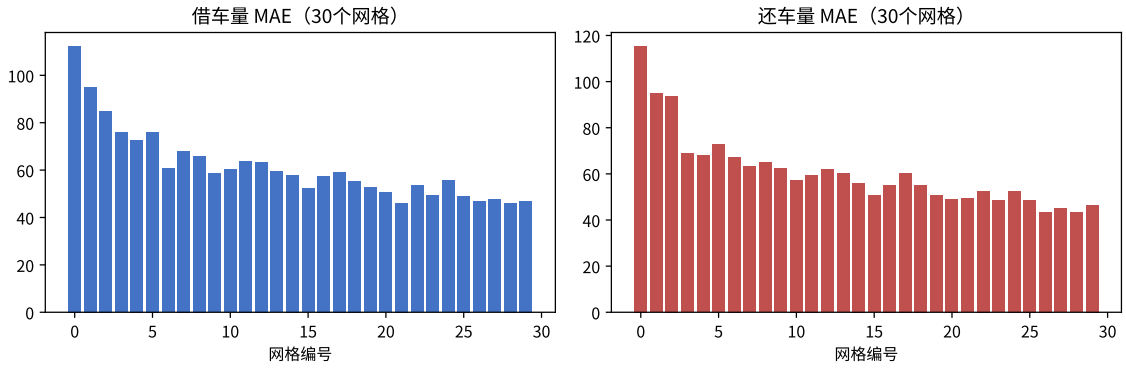


图 5: Transformer 测试集各网格 MAE 分布（左：借车，右：还车）

误差在空间上呈现” 高需求–高误差” 的正相关关系，原因包括：

1. **需求绝对量大**：高峰期单网格 30 分钟订单可达数千辆，即使相对误差仅 10%，绝对 MAE 也远高于低需求网格；
2. **需求波动性更强**：高需求网格对突发事件（天气变化、交通管制、周边活动）更敏感，昨日同期基线难以捕捉这类偏离；
3. **数据量不足**：训练段仅约 31 小时高量数据，模型无法充分学习不同网格在不同时段的差异化模式，只能学到全局性的周期修正。

5 原因总结与讨论

5.1 previous-day 基线为何难以超越

previous-day 基线本质上是把” 昨日同时刻真实需求” 作为预测值，它免费获取了 48 步连续的真实观测信号，对具有强日周期惯性的通勤型出行需求捕捉能力极强。在本数据集上，测试集仅约 2 天且紧邻训练段，日间相关性极高，导致该基线接近” 抄答案” 的效果。

Transformer 残差模型已将 previous-day 作为硬编码起点，模型只学习修正量，但在数据量有限（有效高量训练数据约 31 小时）的条件下，能学到的修正模式非常有限，最终 MAE 仅比基线高 0.6（61.0 vs 60.4），接近但未能超越。

5.2 深度模型的适用条件

结合实验结果与相关文献，Transformer 等深度模型要体现出对简单基线的明显优势，通常需要：

- **更长时间跨度**的数据（数月以上），以学习不同周、不同节假日、不同天气下的多样化模式；
- **测试集与训练集存在真实分布差异**，而非相邻时段的高相关；
- **额外特征**（天气、POI、空间拓扑等），这些是 previous-day 基线完全无法利用的信号。

5.3 本次实验的局限

- 数据覆盖仅 32 天，且前 29 天几乎无有效订单，时间分布严重偏斜；
- 高量数据仅约 4 天，测试集进一步缩减至约 1.4 天，样本量过小；
- 未融合天气、POI 等外部数据；
- 空间维度上 30 个网格独立预测，空间注意力模块虽已实现，但因测试集过短未能体现优势。

6 总结

本作业完成了共享单车需求的时空特征分析、Transformer 残差预测模型的构建与训练，并与 historical_mean、previous-day、LSTM 等基线进行了系统对比。主要结论：

1. 共享单车需求具有明显的日内双峰周期和工作日/周末差异，previous-day 基线因此表现很强；
2. 残差建模使 Transformer 从 previous-day 水平出发学习修正量，有效提升了训练效率与最终精度；
3. 在数据覆盖短、时段单一的不利条件下，Transformer（MAE=61.0）接近 previous-day（60.4）而未超越，反映出深度模型对数据量的依赖；

4. 误差空间分布呈” 高需求–高误差” 特征，主要由需求绝对量大、波动性强和数据不足共同造成。

若后续继续改进，建议优先扩大数据时间跨度、融合天气与 POI 特征，并在更充分的测试条件下重新评估空间注意力的作用。